Actividad de Clase: Aplicación de la Regresión Lineal Múltiple

Analítica Descriptiva

Contexto

En esta actividad aplicarán los conceptos fundamentales de **regresión lineal múltiple** vistos en clase: formulación del modelo, interpretación de coeficientes parciales, prueba F global, pruebas t individuales, R^2 ajustado, multicolinealidad, variables categóricas, interacciones y diagnóstico básico del modelo.

La actividad está diseñada para desarrollarse en **1 hora** y debe resolverse en equipos de **2 o 3 estudiantes**.

Objetivo

Desarrollar un análisis completo de regresión lineal múltiple a partir de una base de datos simulada o construida por ustedes, interpretando adecuadamente los resultados y relacionándolos con la teoría vista en clase.

Producto esperado

Cada equipo deberá entregar un **informe corto** con:

- Planteamiento del problema.
- Descripción de las variables.
- Formulación del modelo.
- Interpretación de resultados.
- Comparación de modelos.
- Diagnóstico y conclusiones.

Situación propuesta

Una universidad quiere analizar qué factores explican el **desempeño final de sus estudiantes** en una asignatura. Para ello, cada equipo trabajará con una base de datos que incluya una variable respuesta y varios predictores.

Variable respuesta sugerida

- **Nota final** o **puntaje final** del estudiante.

Predictores sugeridos

Incluyan al menos:

- **Dos variables numéricas**, por ejemplo:
  - horas de estudio,
  - porcentaje de asistencia,
  - número de tareas entregadas,
  - puntaje diagnóstico,
  - experiencia previa.
- **Una variable categórica**, por ejemplo:
  - modalidad (presencial / virtual / híbrida),
  - jornada (mañana / noche),
  - grupo (A / B / C).

Importante: también deben proponer al menos una posible **interacción** entre un predictor numérico y una variable categórica.

Desarrollo de la actividad

Resuelvan los siguientes puntos en orden.

Parte 1. Planteamiento del modelo

1.1. Definan claramente cuál será la variable respuesta Y.

1.2. Seleccionen al menos **tres predictores**: dos numéricos y uno categórico.

1.3. Escriban el modelo de regresión lineal múltiple en forma escalar:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + \varepsilon_i$$

1.4. Expliquen, con sus palabras, qué representa cada coeficiente β_j como **efecto parcial**.

1.5. Escriban también el modelo en forma matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Parte 2. Análisis conceptual

2.1. Expliquen por qué un modelo con un solo predictor podría generar **sesgo por variable omitida**.

2.2. Describan qué diferencia existe entre:

- una pendiente en regresión lineal simple, y
- un coeficiente en regresión lineal múltiple.

2.3. Indiquen cuál sería el significado práctico de mantener "**lo demás constante**".

Parte 3. Construcción de modelos

Planteen y comparen los siguientes modelos:

3.1. Modelo 1: regresión simple con un solo predictor numérico.

3.2. Modelo 2: regresión múltiple con los predictores numéricos.

3.3. Modelo 3: regresión múltiple con predictores numéricos y la variable categórica.

3.4. Modelo 4: modelo anterior incluyendo una interacción.

Para cada modelo, deben responder:

- ¿Qué variables incluye?
- ¿Qué esperan que ocurra con los coeficientes al agregar nuevas variables?
- ¿Qué modelo creen que explicará mejor la variable respuesta y por qué?

Parte 4. Interpretación de resultados

Una vez estimados los modelos, elaboren un análisis escrito donde respondan:

4.1. ¿Cuál es la interpretación del intercepto?

4.2. ¿Cómo se interpreta cada coeficiente numérico?

4.3. ¿Cómo se interpreta la variable categórica respecto a la categoría de referencia?

4.4. Si incluyeron una interacción, expliquen:

- qué significa,
- cómo cambia la pendiente entre grupos,
- si las rectas serían paralelas o no.

Parte 5. Inferencia estadística

Respondan las siguientes preguntas con base en los resultados del modelo principal:

5.1. ¿El modelo es significativo en conjunto? Expliquen usando la **prueba F global**.

5.2. ¿Cuáles variables son significativas individualmente? Expliquen usando las **pruebas t**.

5.3. ¿Puede ocurrir que la prueba F sea significativa pero alguna prueba t no lo sea? Justifiquen.

Parte 6. Comparación de modelos

Comparen los modelos usando:

- R^2
- R^2 ajustado
- AIC
- BIC

Luego respondan:

6.1. ¿Por qué el R^2 nunca disminuye al agregar predictores?

6.2. ¿Por qué el R^2 ajustado es más útil para comparar modelos?

6.3. ¿Cuál modelo seleccionarían finalmente y por qué?

Parte 7. Multicolinealidad

7.1. Revisen si existe multicolinealidad entre los predictores.

7.2. Expliquen cómo se interpreta el **VIF**.

7.3. Respondan:

- ¿qué consecuencias tiene una multicolinealidad alta?,
- ¿qué podría pasar con los errores estándar?,
- ¿qué acciones tomarían si detectan multicolinealidad severa?

Parte 8. Diagnóstico del modelo

Analicen los supuestos del modelo mediante residuos y respondan:

8.1. ¿Se observa algún patrón en el gráfico de residuos vs. ajustados?

8.2. ¿La normalidad de residuos parece razonable?

8.3. ¿Existen observaciones con leverage alto o distancia de Cook elevada?

8.4. Si encuentran observaciones influyentes, expliquen si necesariamente deben eliminarse.

Parte 9. Conclusión final

Redacten un cierre de **8 a 10 líneas** donde respondan:

- ¿Qué variables explican mejor la respuesta?
- ¿El efecto de alguna variable cambió al controlar por otras?
- ¿Hubo evidencia de interacción?
- ¿El modelo elegido parece útil para explicar o predecir?

Entregable

El informe debe incluir, como mínimo, las siguientes secciones:

1. Título de la actividad.
2. Integrantes.
3. Descripción del problema.
4. Variables usadas.
5. Modelos planteados.
6. Interpretación de resultados.
7. Comparación de modelos.
8. Diagnóstico.
9. Conclusión final.

Tiempo estimado

Actividad	**Tiempo**
Planteamiento del problema y variables	10 min
Construcción de modelos	15 min
Interpretación e inferencia	15 min
Comparación y diagnóstico	10 min
Conclusión y organización del informe	10 min

Criterios de evaluación

Criterio	**Puntaje**
Planteamiento correcto del modelo	1.0
Interpretación adecuada de coeficientes	1.5
Comparación correcta entre modelos	1.5
Uso adecuado de F global y pruebas t	1.0
Análisis de multicolinealidad y diagnóstico	1.0
Conclusión clara y coherente	1.0
Orden, redacción y presentación	1.0
Total	**8.0**

Recomendaciones

- No se limiten a copiar resultados: **interpreten**.
- Relacionen cada resultado con la teoría vista en clase.
- Sean claros al diferenciar **significancia global** y **significancia individual**.
- Justifiquen siempre la selección del modelo final.

Fin de la actividad